PROYECTO FINAL · DEEP LEARNING Y SISTEMAS INTELIGENTES 2026 · UVG

¿Mantenemos este modelo en producción?

Monitoreo transaccional del Banco del Altiplano: un ensamble LightGBM + GRU decide, con LightGBM solo en sombra

Andrés Mazariegos · June Herrera

Modelo de origen: Proyecto 1 · Prof. Kevin Recinos · noviembre 2026

1 · PROBLEMÁTICA

Cada transacción se decide en milisegundos, sin saber todavía si es fraude

DEJAR PASAR UN FRAUDE

Q4,200

BLOQUEAR A UN CLIENTE LEGÍTIMO

Q180

Un error es 23 veces más caro que el otro: el umbral no puede estar en 50 %.

LA DECISIÓN QUE DEPENDE DEL MODELO

PROBABILIDAD CALIBRADA	ACCIÓN	QUIÉN
≥ 2.2 %	Bloquear	automático
0.91 % – 2.2 %	Revisar	analista (≤ 1 % del tráfico)
< 0.91 %	Aprobar	automático

USUARIOS

Sistema autorizador — llama a la API por transacción, necesita p95 < 100 ms.

Analista de riesgos — atiende la cola de revisión y necesita saber *por qué*.

Este comité — decide con el panel si el modelo se mantiene, se reentrena o se reemplaza.

Hipótesis escrita antes de entrenar; paridad probada antes de desplegar

ETAPA	FECHA	RESPONSABLE
Elegir modelo (P1 sobre P2 y P3)	8 nov	Ambos
Congelar hipótesis y criterio	8 nov 20:26	A. Mazariegos
Reentrenar K = 3, paquete de producción	8 nov	J. Herrera
API, demo, registro, monitoreo	8 nov	A. Mazariegos
Pruebas de contrato y paridad	8 nov	J. Herrera
H3 (ensamble) y decisión de producción	8 nov 21:41	Ambos
Despliegue y tráfico de prueba	9 nov	A. Mazariegos · J. Herrera
Monitoreo y versión final	≤ 15 nov	Ambos

DATOS

Sintéticos (generador del P1, misma semilla): 419,821 transacciones, 4,000 tarjetas, 1.18 % fraude. Partición **temporal**. Las etiquetas llegan días después (contracargos).

USUARIO

El autorizador envía 7 días de historia. Los analistas revisan ≤ 1 % del tráfico. Costos promedio fijos.

ENTORNO

CPU, 2 vCPU / 2 GiB (Google Cloud Run, escala a cero). Registro efímero, exportable a CSV.

Del Proyecto 1: K = 20 → 3, y después un ensamble con LightGBM

LO QUE DIJO EL PROYECTO 1 DE SÍ MISMO

Su propia prueba de recorte de historia mostró que el GRU con `K = 20` estaba en su **peor** configuración (0.636 de AUC-PR contra 0.749 con `K = 3`), y que el resultado dependía mucho de la semilla (± 0.068).

POR QUÉ TENDRÍA SENTIDO

El patrón "sondeo y golpe" vive en las últimas transacciones. Con 20 pasos el GRU tenía que aprender a ignorar 17 pasos de relleno o ruido en 30 épocas.

SERVIDO — ENSAMBLE E = 0.5 · A + 0.5 · C_K3

C_K3 (Deep Learning): últimas 3 transacciones → 7 numéricas + embeddings (rubro, canal, comercio) → **GRU 64** con máscara → ⊕ 30 agregados → Dense 32 → sigmoide · 27,457 parámetros

A: LightGBM sobre 30 agregados causales, ciegos al orden

Peso 0.5 fijado antes de calcular nada. Se calibra el promedio.

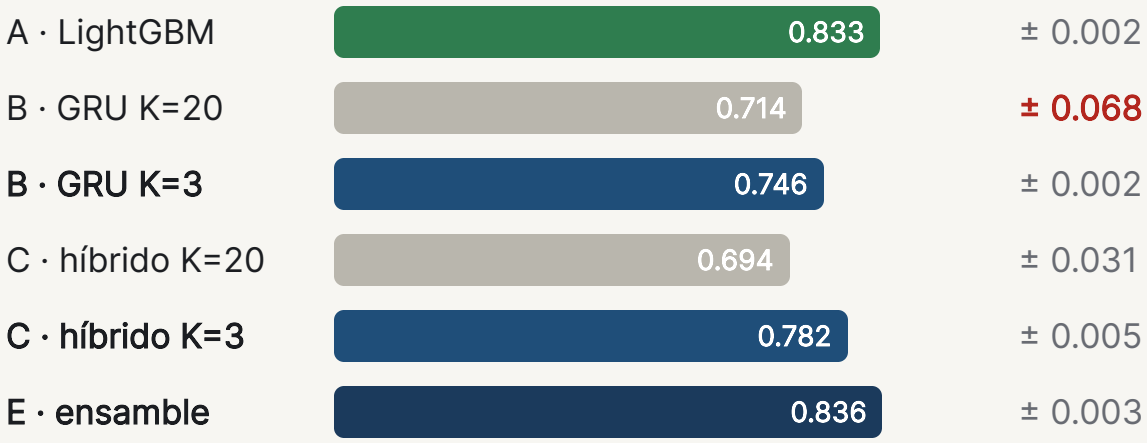
POR QUÉ COMBINARLOS

A no puede ver el orden; el GRU sí lo usa. Si fallan en casos distintos, el promedio corrige parte de cada uno.

4 · VALIDACIÓN DE HIPÓTESIS

H1 se cumple; H2 y H3 no. El GRU dejó de depender de la suerte

AUC-PR de validación, media de 3 semillas (barra) ± desviación



H1 y H2 registradas antes de entrenar (02:26 UTC). H3 registrada en su propio commit antes de calcular el ensamble (03:41 UTC). El entrenamiento guarda el SHA-256 del archivo.

H1 · GRU K=3 > GRU K=20

Criterio: +0.03 en la media **y** peor semilla > 0.714

+0.032 · peor semilla 0.743 **Se cumple**

H2 · HÍBRIDO K=3 ≥ LIGHTGBM

Criterio: media ≥ A − 0.005

−0.051 **No se cumple**

H3 · ENSAMBLE NO PEOR QUE A

Criterio: AUC-PR ≥ A **y** costo ≤ A

+0.0035 AUC-PR, pero Q281,720 vs Q270,560

No

Permutación: barajar la ventana del GRU baja su AUC-PR de 0.786 a 0.661 → **sí** usa el orden.

4 · REGLA TÉCNICA VS. DECISIÓN DE NEGOCIO · PRUEBA EVALUADA UNA VEZ

Por la regla gana LightGBM por poco; decidimos que el ensamble decida

PRUEBA (13 DÍAS, 703 FRAUDES)	AUC-PR	RECALL	COSTO	AHORRO / MES
E — ensamble (decide)	0.853	97.6 %	Q263 k	**Q6.01 M**
A — LightGBM (sombra)	0.857	97.7 %	Q261 k	Q6.02 M
C_K3 — GRU solo	0.789	94.2 %	Q365 k	Q5.79 M
Sin modelo	—	0 %	Q2.95 M	—

EL COSTO DE LA DECISIÓN, DICHO EN VOZ ALTA

El ensamble cuesta **Q4,560 más al mes** que LightGBM solo: el **0.08 %** del ahorro. Es el precio de que el Deep Learning participe en cada decisión.

REGLA TÉCNICA (CONGELADA)

H3 pedía AUC-PR *y* costo. Falla el costo → **decide A**. Los artefactos lo reflejan así y no se tocaron.

DECISIÓN DE NEGOCIO · DECISION.MD

Promover E con una línea del Dockerfile: `PROMOVER_RETADOR=1`. Sin reentrenar; reversible quitando la línea.

POR QUÉ A SIGUE CORRIENDO

En sombra, para que el panel diga con tráfico real si la decisión se sostiene.

Datos → entrenamiento → servicio → monitoreo

Datos
Generador P1 (semilla fija) · partición temporal train / val / test

→

Entrenamiento
Features del P1 · LightGBM ×3 · GRU ×3 · ensamble · regla congelada · calibración + u* en val · ~10 min CPU

→

Artefactos
modelos · scalers · vocabularios · umbrales · referencia PSI · metadata con hash de hipótesis

↓

Servicio · Docker en Google Cloud Run
FastAPI + Uvicorn (2 procesos) · `POST /predecir` · **ensamble decide**, LightGBM en sombra · puntaje por componente + motivos SHAP · validación de entradas (422)

→

Registro
SQLite: cada predicción + etiqueta que llega después (`/retroalimentacion`)

→

Monitoreo
`/monitor`: latencia, PSI de puntaje y entradas en ventana móvil, costo real de campeón vs. retador

Clave del diseño: el servicio **no reimplementa ninguna feature**. Arma un mini-DataFrame con la historia + la transacción y llama a las *mismas* funciones del entrenamiento.

Keras 3 (torch) · LightGBM · FastAPI · Pydantic · SQLite · Chart.js local · Docker `python:3.13-slim` + torch CPU

76 pruebas automáticas; la más importante atrapó un bug antes de desplegar

PARIDAD ENTRENAMIENTO ↔ SERVICIO

40 transacciones reales del periodo de prueba (15 fraudes), puntuadas por el pipeline por lotes y por la API. Diferencia máxima permitida: **0.00001**, para el ensamble y para LightGBM.

Primera corrida: falló — timestamps con y sin microsegundos se parseaban con un solo formato. Corregido: pasa

HISTORIA RECORTADA

Mandar toda la historia o solo 7 días da el mismo puntaje → el contrato de 7 días es suficiente.

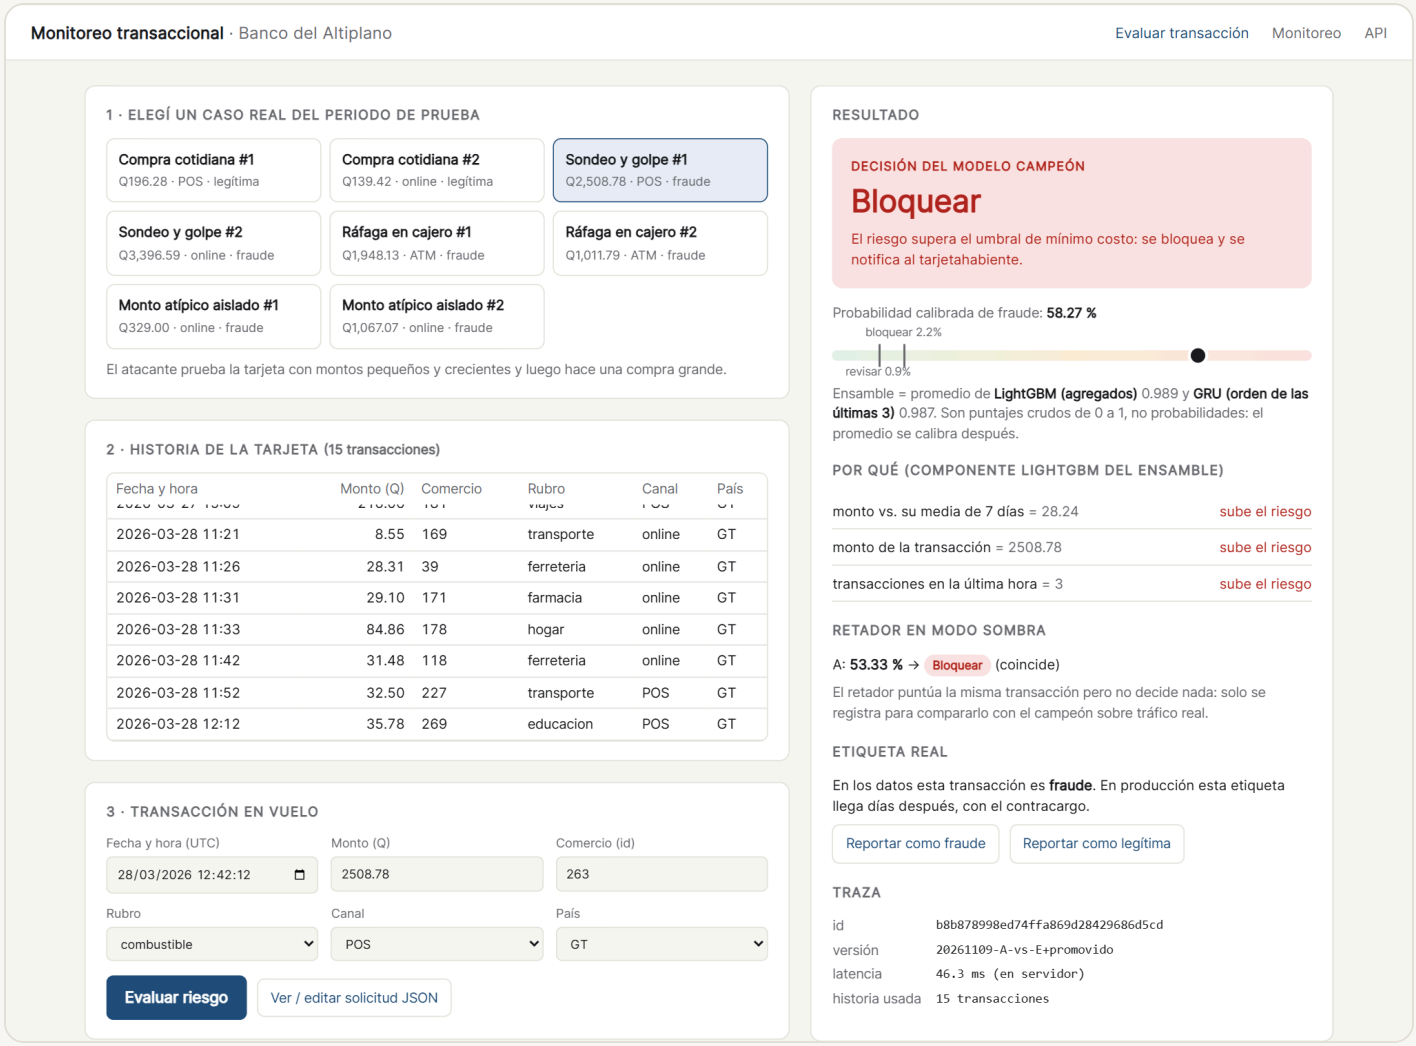
CONTRATO DE LA API

- Decisión siempre coherente con los umbrales
- 422 ante canal, rubro, monto o fecha inválidos
- 422 si la transacción es anterior a su historia
- Retroalimentación, exportación CSV, promoción de roles

MONITOREO

El PSI calla con tráfico estable y alerta con montos inflados o un canal nuevo.

Demo: un "sondeo y golpe" real del periodo de prueba



LO QUE VE EL ANALISTA

Varias compras pequeñas en línea en 20 minutos (Q8, Q28, Q29, Q85…) y, una hora después, Q2,509 en una gasolinera. Riesgo 58 % → **Bloquear**.

POR QUÉ

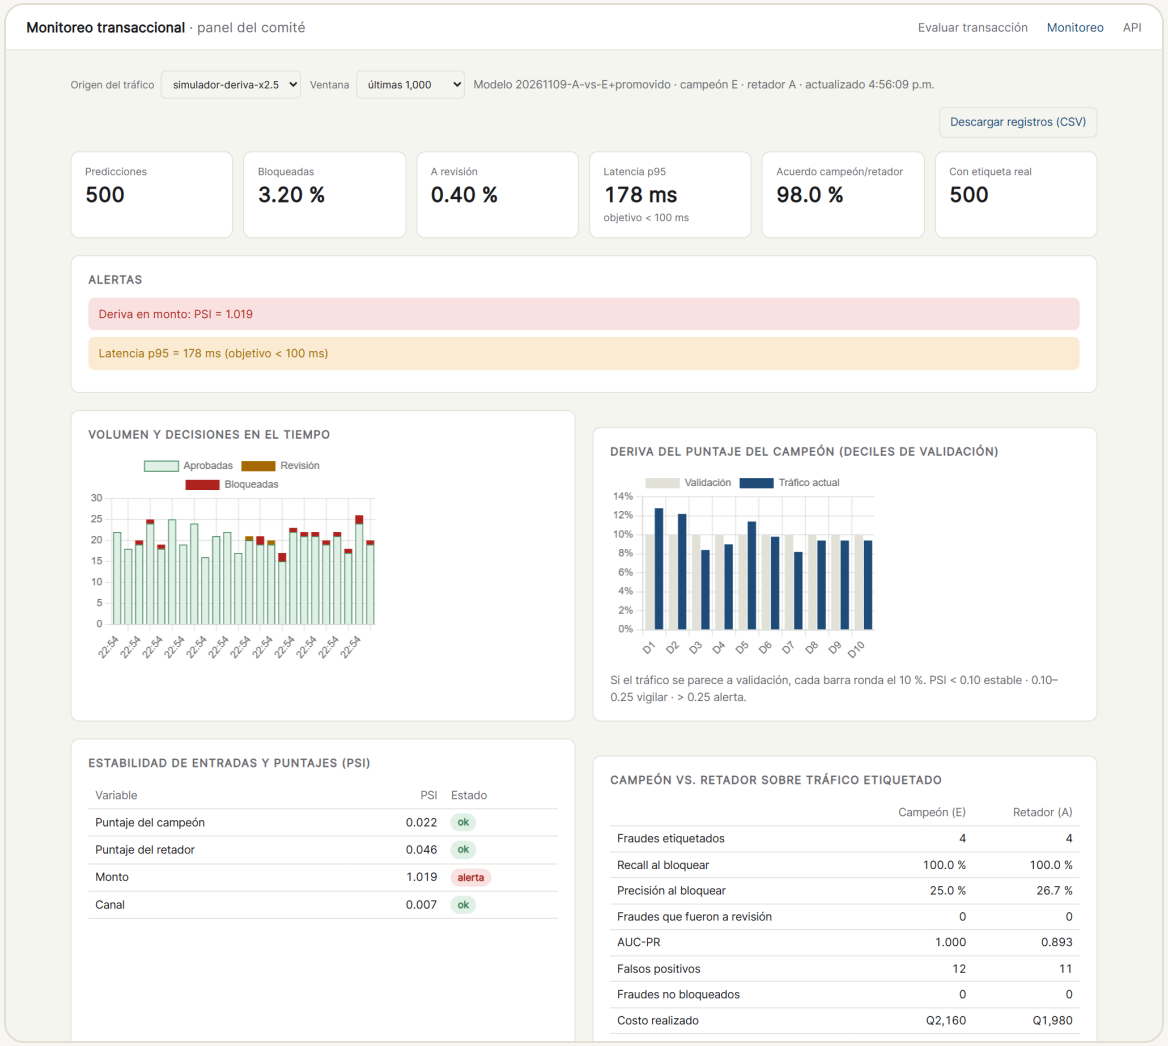
LightGBM 0.989 y GRU 0.987: ambas mitades lo ven. Monto 28× su media de 7 días · 3 transacciones en la última hora.

LIGHTGBM EN SOMBRA

53 % → también bloquearía.

URL: *monitoreo-transaccional-837352528666.us-central1.run.app* · `/docs` para la API

Más de 3,000 transacciones reproducidas, 0 errores; el monitoreo encontró dos cosas



2,000 TX · 43 FRAUDES · PRODUCCIÓN	RECALL	COSTO
E — ensamble (decide)	100 %	**Q6,120**
A — LightGBM (sombra)	100 %	Q6,300
Sin modelo	0 %	Q180,600

1 · LATENCIA

Local: 1 proceso p95 = 252 ms (GIL); 2 procesos p95 88–139 ms, salvo una corrida (239 ms). **Cloud Run, 4 clientes: p50 91 ms, p95 166–178 ms** ✕ > 100 ms

2 · DERIVA (MONTOS ×2.5)

PSI del monto = **1.02 → alerta** (local y en producción); PSI del puntaje = 0.02. Las entradas cambiaron, el modelo no: usa montos *relativos*. Alerta de entrada ≠ modelo roto.

RECOMENDACIÓN AL COMITÉ

Mantener el ensamble, con LightGBM en sombra cuatro semanas

DECISIÓN QUE PROPONEMOS

- **Mantener** el ensamble: ahorra ~Q6 M/mes frente a no tener modelo, con el GRU en cada decisión.
- **Revisar cada semana** en el panel el costo realizado de ambos sobre el mismo tráfico.
- **Volver a LightGBM** si, con ≥ 200 fraudes etiquetados, sigue siendo más barato (una línea del Dockerfile).

DISPARADORES DE REENTRENAMIENTO

PSI del puntaje > 0.25 · tasa de bloqueo > 3× la esperada · recall al bloquear < 90 %

RIESGOS QUE NO ESCONDEMOS

- **Datos sintéticos**: probamos el sistema, no que el patrón exista así en el banco.
- El ensamble decide por decisión de negocio, no por la regla (−Q4,560/mes).
- Calibrador y umbral heredan el optimismo de validación.
- Costos fijos: en la realidad un FN escala con el monto.
- p95 > 100 ms con tráfico concurrente; registro efímero; sin autenticación.

SIGUIENTE ITERACIÓN

Elegir el peso del ensamble con un conjunto de datos nuevo, que no se haya usado para calibrar ni para fijar el umbral.